


Python for Machine Learning

Dari data mentah → data bersih → informasi visual → fitur siap dimodelkan



Google Colab • NumPy • Pandas • Matplotlib • Scikit-Learn

Posisi Pertemuan 06 dalam RPS

Pertemuan 06 adalah bagian awal blok 06–07: Python for ML dan pengolahan data.

SUB-CPMK 9.1

Terampil menggunakan pustaka Python dan menggunakannya untuk membangun proses pengolahan data ML.

MATERI RPS

NumPy • Pandas • Matplotlib • Scikit-Learn
Fokus: manipulasi data mentah menjadi informasi visual.

ALOKASI

RPS menggabungkan minggu 06–07 selama 300 menit.
Pertemuan 06 difokuskan pada fondasi coding dan data preparation.

Jembatan dari Pertemuan 05

Probabilitas & ketidakpastian → sekarang: Python untuk mengolah data yang akan dipakai model ML

Tujuan Pembelajaran

Target kemampuan yang dapat diamati setelah praktikum.

01 NumPy

Merepresentasikan dan memproses data numerik sebagai array.

02 Pandas

Membaca, memeriksa, membersihkan, dan mentransformasi data tabular.

03 Visualisasi

Membuat grafik sederhana untuk menemukan pola dan masalah data.

04 Scikit-Learn

Mengenali alur awal data → preprocessing → model.

05 Interpretasi

Menjelaskan perubahan data dan alasan setiap langkah preprocessing.

Studi Kasus: Data Mahasiswa

Kita akan mengubah data yang belum rapi menjadi informasi yang dapat dibaca.

DATA MENTAH

Kolom: nama, kehadiran, tugas, IPK, jam belajar, status.

Masalah yang sengaja dimasukkan:

- missing value
- format angka tidak konsisten
- duplikasi
- kategori tidak konsisten

PERTANYAAN


1. Apa masalah pada dataset?
2. Bagaimana memperbaikinya?
3. Apakah perubahan data dapat dilacak?
4. Pola apa yang terlihat setelah cleaning?

HASIL AKHIR

Dataset lebih konsisten → statistik ringkas → visualisasi → fitur yang lebih siap digunakan untuk model ML.

Workflow Praktikum Hari Ini

Gunakan urutan ini agar mahasiswa tidak langsung “loncat” ke modeling.



Prinsip: jangan membersihkan data tanpa tahu masalah apa yang sedang diperbaiki.

1. NumPy - Fondasi Data Numerik

NumPy menyediakan struktur array dan operasi numerik yang efisien.

GOOGLE COLAB

```
import numpy as np

X = np.array([
    [90, 3.70, 8],
    [75, 3.20, 5],
    [88, 3.60, 7]
])

print("Shape:", X.shape)
print("Mean :", X.mean(axis=0))
print("Min  :", X.min(axis=0))
print("Max  :", X.max(axis=0))
```

SHAPE

(3, 3) = 3 observasi × 3 fitur.

AXIS=0

Operasi per kolom/fitur.

MENGAPA PENTING?

Model ML bekerja pada representasi numerik yang terstruktur.

2. Pandas - Membaca Data Tabular

Pandas membantu kita bekerja dengan DataFrame yang menyerupai tabel.

GOOGLE COLAB

```
import pandas as pd

df = pd.read_csv("data_mahasiswa.csv")

print(df.head())
print(df.shape)
print(df.columns)
print(df.info())
```

df.head()

Melihat beberapa baris awal.

df.shape

Mengetahui jumlah baris dan kolom.

df.info()

Mengecek tipe data dan nilai non-null.

Langkah Pertama: Jangan Langsung Cleaning

Cari tahu kondisi dataset sebelum mengubah apa pun.

GOOGLE COLAB

```
print(df.head())
print(df.tail())

print("\nMissing value:")
print(df.isna().sum())

print("\nDuplikasi:", df.duplicated().sum())

print("\nStatistik:")
print(df.describe())
```

MISSING

Apakah ada nilai kosong?

DUPLIKASI

Apakah ada baris yang berulang?

DISTRIBUSI

Apakah nilai masuk akal?

Mengenali Masalah Data

Cleaning bukan menghapus data sembarangan; setiap tindakan harus punya alasan.

Missing value

Kehadiran = NaN

Isi/estimasi atau keluarkan baris sesuai konteks

Duplikasi

Baris mahasiswa muncul 2×

Pertahankan satu observasi yang valid

Tipe data

IPK terbaca sebagai string

Konversi ke numerik

Kategori

Lulus / lulus / LULUS

Standarkan kategori

Cleaning 1 - Menangani Missing Value

Pilih strategi berdasarkan makna data, bukan sekadar agar error hilang.

GOOGLE COLAB

```
# Cek jumlah missing
print(df.isna().sum())

# Contoh: isi IPK dengan median
df["IPK"] = df["IPK"].fillna(
    df["IPK"].median()
)

# Cek ulang
print(df.isna().sum())
```

DROP

Hapus baris/kolom jika memang tidak layak digunakan.

FILL

Isi dengan mean/median/mode atau aturan domain.

CATAT

Dokumentasikan keputusan preprocessing.

Cleaning 2 - Menghapus Duplikasi

Duplikasi dapat membuat satu observasi dihitung lebih dari sekali.

GOOGLE COLAB

```
print("Duplikasi sebelum:",  
      df.duplicated().sum())  
  
df = df.drop_duplicates()  
  
print("Duplikasi sesudah:",  
      df.duplicated().sum())  
  
print("Shape akhir:", df.shape)
```

SEBELUM

Identifikasi dulu jumlah baris duplikat.

TINDAKAN

`drop_duplicates()` menghapus baris duplikat.

VALIDASI

Bandingkan shape sebelum dan sesudah.

Cleaning 3 - Menyamakan Tipe Data

Angka yang tersimpan sebagai teks dapat mengganggu perhitungan.

GOOGLE COLAB

```
print(df.dtypes)

df["Kehadiran"] = pd.to_numeric(
    df["Kehadiran"], errors="coerce"
)

df["IPK"] = pd.to_numeric(
    df["IPK"], errors="coerce"
)

print(df.dtypes)
```

PROBLEM

“85” sebagai string ≠ 85 sebagai angka.

TOOL

pd.to_numeric(..., errors="coerce")

PERIKSA

Setelah konversi, cek kembali missing value.

Cleaning 4 - Menstandarkan Kategori

Kategori harus konsisten agar tidak dianggap sebagai kelas yang berbeda.

GOOGLE COLAB

```
print(df["Status"].value_counts())

df["Status"] = (
    df["Status"]
    .astype(str)
    .str.strip()
    .str.lower()
)

mapping = {
    "lulus": "Lulus",
    "tidak lulus": "Tidak Lulus"
}

df["Status"] = df["Status"].replace(mapping)

print(df["Status"].value_counts())
```

STRIP

Menghapus spasi yang tidak perlu.

LOWER

Menyamakan bentuk huruf.

REPLACE

Mengubah label menjadi kategori standar.

Setelah Cleaning: Cek Lagi

Cleaning yang baik selalu diikuti pemeriksaan ulang.

GOOGLE COLAB

```
print("Shape :", df.shape)
print("Missing:")
print(df.isna().sum())

print("\nDuplikasi:",
      df.duplicated().sum())

print("\nTipe data:")
print(df.dtypes)

print("\nKategori status:")
print(df["Status"].value_counts())
```

CHECK 1

Shape dan jumlah observasi.

CHECK 2

Missing dan duplikasi.

CHECK 3

Tipe data dan kategori.

CHECK 4

Nilai tetap masuk akal.

Matplotlib - Melihat Data, Bukan Sekadar Angka

Visualisasi membantu menemukan pola, perbedaan, dan anomali.

GOOGLE COLAB

```
import matplotlib.pyplot as plt

plt.figure(figsize=(7,4))
plt.hist(df["IPK"], bins=6)
plt.xlabel("IPK")
plt.ylabel("Jumlah Mahasiswa")
plt.title("Distribusi IPK")
plt.show()
```

HISTOGRAM

Melihat distribusi satu variabel numerik.

PERTANYAAN

Apakah data terkonsentrasi atau menyebar?

INTERPRETASI

Grafik harus menghasilkan pertanyaan/insight.

Membandingkan Fitur dengan Target

Contoh: apakah kehadiran berkaitan dengan status kelulusan?

GOOGLE COLAB

```
plt.figure(figsize=(7,4))

df.boxplot(
    column="Kehadiran",
    by="Status"
)

plt.title("Kehadiran vs Status")
plt.suptitle("")
plt.xlabel("Status")
plt.ylabel("Kehadiran (%)")
plt.show()
```

BOXPLOT

Membandingkan distribusi numerik antar kelompok.

HINDARI

Jangan menyimpulkan sebab-akibat hanya dari grafik.

TUJUAN

Gunakan visualisasi untuk eksplorasi dan validasi.

Eksplorasi Ringkas dengan GroupBy

Sebelum modeling, ringkas data untuk memahami hubungan sederhana antar variabel.

GOOGLE COLAB

```
ringkasan = (  
    df.groupby("Status")  
        .agg(  
            rata_kehadiran=("Kehadiran", "mean"),  
            rata_ipk=("IPK", "mean"),  
            rata_jam_belajar=("Jam_Belajar", "mean")  
        )  
)  
  
print(ringkasan.round(2))
```

GROUPBY

Mengelompokkan data berdasarkan kategori.

AGG

Menghitung statistik ringkas per kelompok.

INSIGHT

Membantu menentukan pertanyaan modeling.

4. Scikit-Learn - Masuk ke Workflow ML

Hari ini belum mengejar model kompleks; kita pahami antarmuka data untuk modeling.

GOOGLE COLAB

```
from sklearn.model_selection import train_test_split

features = ["Kehadiran", "IPK", "Jam_Belajar"]
X = df[features]
y = df["Status"]

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)

print(X_train.shape, X_test.shape)
```

X

Feature/input yang digunakan model.

y


Target/label yang ingin diprediksi.

SPLIT

Pisahkan train dan test agar evaluasi lebih jujur.

Dari Data Mentah ke Data Model

Mahasiswa perlu melihat gambaran besar sebelum menulis banyak kode.



Data cleaning bukan tahap terpisah dari ML - ia bagian dari pipeline.

Praktikum Terbimbing - Satu Notebook, Satu Alur

Jalankan cell secara berurutan. Setelah setiap tahap, baca outputnya.

01 Load

Baca CSV dan tampilkan 5 baris pertama.

02 Inspect

Cek shape, tipe data, missing, duplikasi.

03 Clean

Perbaiki missing, duplikasi, dan tipe data.

04 Explore

Gunakan describe dan groupby.

05 Visualize

Buat histogram dan boxplot.

06 Prepare

Pisahkan X dan y; train-test split.

Latihan Mandiri di Colab

Mahasiswa mengubah satu parameter dan menjelaskan dampaknya.

LATIHAN A

Ubah strategi missing value:

- median $\rightarrow$ mean

Bandingkan nilai hasil cleaning.

LATIHAN B

Buat grafik baru:

- scatter Kehadiran vs IPK

Tambahkan judul dan label sumbu.

LATIHAN C

Ubah test_size:

0.2 $\rightarrow$ 0.3

Catat perubahan jumlah train/test.

Wajib: tulis 3–5 kalimat interpretasi di Markdown.

Challenge: Temukan 3 Masalah Data

Kerjakan tanpa mengikuti langkah dosen satu per satu.

Gunakan dataset praktikum dan cari minimal tiga masalah kualitas data.

1

Temukan

Tunjukkan bukti dari output Python.

2

Perbaiki

Gunakan kode yang sesuai.

3

Validasi

Buktikan masalah sudah tertangani.

4

Jelaskan

Apa dampaknya jika tidak diperbaiki?

Checklist Ketercapaian

Sebelum selesai, pastikan mahasiswa dapat menjelaskan proses, bukan hanya menjalankan kode.

- ✓ Saya dapat membaca CSV menjadi DataFrame.
- ✓ Saya dapat mengecek missing value dan duplikasi.
- ✓ Saya dapat memperbaiki tipe data yang tidak sesuai.
- ✓ Saya dapat membuat minimal dua visualisasi.
- ✓ Saya memahami perbedaan feature (X) dan target (y).
- ✓ Saya dapat menjelaskan mengapa data perlu dibersihkan sebelum modeling.

Target: 6/6 dapat dijelaskan

Pertemuan 06 → Data Siap untuk Machine Learning

01

NumPy

Data numerik → array & operasi

02

Pandas

Tabel → inspeksi & cleaning

03

Matplotlib

Data → visualisasi & eksplorasi

04

Scikit-Learn

X/y → train-test split

Pertemuan berikutnya: lanjutkan pengolahan data → visualisasi → persiapan eksperimen model ML.

Prinsip utama: clean data → understand data → prepare data → model.